EviRefine：证据引导的粗到精多变量时间序列缺失修复

匿名作者

中文逻辑对照稿 v0.1：与英文稿章节、公式及数据对应

本版本用于核对论证逻辑；表格数值与英文版由同一数据快照生成，分页不要求一致。

摘要

多变量时间序列缺失修复需要从时间与变量维度上分布不均的观测中重建局部轨迹。其关键在于融合互补的上下文与 Patch 信息，并保持恢复数值与真实可见测量的一致性。本文提出证据引导的粗到精修复框架 EviRefine，包含时间–变量上下文编码、多来源 Patch 证据检索、逐点证据引导重建和观测条件化残差精恢复四个组件。上下文编码捕捉时间动态与跨变量依赖；Patch 检索将当前窗口及训练历史片段组织为统一证据库，由各目标点分别读取以增强上下文基础估计；残差精恢复进一步结合初始估计、可见观测和观测导出的参考信息，纠正重建误差。实验覆盖六个不同应用领域的数据集。在与容量匹配上下文模型的三训练种子配对实验中，证据路径使 ETTh1 和 PAMAP2 的最终 MSE 分别降低 5.19% 和 2.39%。组件、缺失条件及效率分析进一步呈现 Patch 证据与观测条件化精恢复对缺失重建的作用。

1 引言

多变量时间序列记录了环境监测、生理传感、工业系统和金融市场中相互关联的动态过程。缺失观测以不同位置和持续时间打断这些过程，同时遮蔽局部动态与变量之间的联系。恢复缺失值需要融合这些互补维度上的可用信息。

现有方法通过循环估计、自注意力、扩散以及结构化时空表示建模不完整观测 [1, 2, 4, 7]。时间 Patch 为局部轨迹提供了有效的表示单元 [5]，变量注意力则捕捉不同测量过程之间的依赖 [3, 6]。这些进展引出了缺失修复的两个互补要求：在受损局部上下文之外寻找有用片段，以及将上下文表示转化为与可见测量一致的数值估计。

可用信息随缺失模式变化。同变量片段可以揭示时间变化，相关变量可以呈现共同转折，训练历史片段则可以提供重复出现的轨迹。不同证据在目标 Patch 内部的作用也随位置变化：靠近可见边界和位于缺口深处的点具有不同的局部支撑。因此，模型按来源组织 Patch 证据，并在单个缺失点的粒度上读取这些信息。

初始估计形成后，可见观测又为数值修正提供了依据。剩余测量锚定轨迹的水平与局部变化，独立的精恢复阶段可以结合初始估计与这些观测，纠正窗口中的剩余误差。由此形成粗到精设计：上下文重建提供初始轨迹，观测条件化精恢复进一步改善逐点数值。

基于上述考虑，本文提出证据引导的粗到精修复框架 EviRefine，包含四个组件：(1) 时间–变量上下文编码（TVCE）；(2) 多来源 Patch 证据检索（MPER）；(3) 逐点证据引导重建（PEGR）；(4) 观测条件化残差精恢复（OCRR）。TVCE 结合残差时间卷积与变量签名注意力；MPER 将时间、

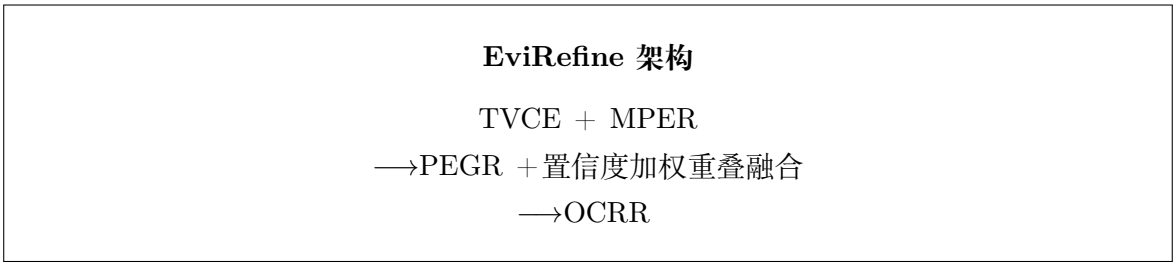


图 1: EviRefine 结构概览。TVCE 编码点级上下文，MPER 构建 Patch 证据，PEGR 生成粗重建，OCRR 结合可见观测进行精恢复。

跨变量和训练历史 Patch 组织为统一证据库；PEGR 由各目标点分别读取证据，并结合 Query 与读取结果修正基础估计；OCRR 进一步融合固定粗估计、可见观测及参考特征，生成精恢复窗口。

本工作的主要贡献如下：

- 提出粗到精修复框架 EviRefine，融合上下文重建、显式 Patch 证据和观测条件化修正，实现多变量时间序列缺失恢复。
- 设计多来源 Patch 证据检索与逐点重建机制，通过统一读取接口，为不同目标点提供互补的时间、跨变量及历史片段。
- 设计观测条件化残差精恢复器，将时间修正与可见观测参考结合。六个数据集的实验与配对组件分析评价整体框架及其恢复机制。

2 相关工作

多变量时间序列缺失修复。 深度修复模型利用时间依赖与变量关系重建缺失观测。BRITS 采用双向循环估计 [1]，SAITS 采用对角掩码自注意力 [2]；CSDI 通过分数扩散建模条件分布 [7]，ImputeFormer 引入低秩时空注意力 [4]。本文将上下文估计、显式 Patch 证据以及后续观测条件化修正整合为统一恢复流程。

时间与跨变量表示。 PatchTST 使用时间 Patch 表示局部轨迹 [5]，iTransformer 建模变量 Token 之间的依赖 [3]。T1 将时间特征通道与变量注意力头绑定 [6]。TVCE 采用这一通道–注意力头交互几何构建变量签名注意力；MPER 和 PEGR 通过按来源组织的片段与逐点读取增强上下文重建；OCRR 则利用真实可见观测修正数值估计。

结构化时间建模。 TimeMixer++ 结合多种表示与混合操作捕捉时间模式，并通过消融、表示、效率和敏感性实验分析组件 [9]。面向缺失修复，本文围绕点级上下文、Patch 证据与观测条件化修正组织信息，通过容量匹配对照、公共精恢复以及掩码定义的误差分层，分析设计选择与重建表现之间的联系。

3 EviRefine 方法

3.1 问题定义与整体结构

令 $\mathbf{X} \in \mathbb{R}^{L\times C}$ 为多变量窗口，$\mathbf{V}$ 表示数据原本具有真值的位置，$\mathbf{M} \le \mathbf{V}$ 表示人工遮挡后保留的可见位置。原生缺失不作为监督真值。以 $\mathbf{X}_{\text{obs}}$ 表示可见值，并将不可用位置置零。评价支撑与可见值保护定义为

$$\begin{aligned} \mathbf{E} &= \mathbf{V} \odot (\mathbf{1} - \mathbf{M}), \\ \widehat{\mathbf{X}} &= \mathbf{M} \odot \mathbf{X}_{\text{obs}} + (\mathbf{1} - \mathbf{M}) \odot f(\mathbf{X}_{\text{obs}}, \mathbf{M}). \end{aligned} \tag{1}$$

公式省略批次维度。推理使用输入窗口中的可见观测和符合资格的训练记忆。

EviRefine 包含证据引导的粗恢复与观测条件化的残差精恢复两阶段（图1）。粗恢复生成训练集标准化尺度的显式估计 $\mathbf{X}^{\text{c}}$；精恢复将该估计作为固定输入并输出 $\widehat{\mathbf{X}}$。粗恢复由 TVCE、MPER 和 PEGR 组成，OCRR 承担第二阶段数值修正，共同恢复不完整输入窗口。

3.2 时间–变量上下文编码（TVCE）

TVCE 结合局部时间动态与跨变量依赖，为各目标点建立上下文表示。首先使用训练集统计进行变量标准化，再依据窗口内可见观测得到每个变量的均值 μ_c 和标准差 σ_c，必要时使用训练统计回退。数值变换前先施加掩码。共享滤波器的残差时间 CNN 逐变量处理可见数值、掩码、时间位置及到可见点的距离，并用全局水平信息补充局部表示。

变量签名注意力在完整时间特征签名之间交换信息。遵循 T1 的 Channel–Head 交互几何 [6]，每个特征通道对应一条变量注意力路径。模型包含两个时间残差块和两个变量注意力块，再对点级特征按重叠 Patch 池化：

$$\begin{aligned} \mathbf{F} &= \mathrm{VSAttn}\big(\mathrm{CNN}(\mathbf{X}_{\text{obs}}, \mathbf{M})\big), \\ z_{j,c} &= \phi_{\text{patch}}([P^x_{j,c}; P^m_{j,c}]) + \psi\big(\mathrm{Pool}(\mathbf{F}_{\mathcal{P}_j,c})\big). \end{aligned} \tag{2}$$

其中 VSAttn 表示变量签名注意力，$\mathcal{P}_j$ 表示第 j 个 Patch，P^x, P^m 是可见数值和掩码，ψ 包含池化上下文的投影。固定 $L = 96$、Patch 长度 16、步长 8、特征宽度 64。基础重建头由 $z_{j,c}$ 产生 16 维预测 $b_{j,c}$。

3.3 多来源 Patch 证据检索（MPER）

MPER 利用来源可辨的互补片段增强目标上下文。针对每个受损目标 Patch，构建三类来源的候选集合 $\mathcal{C}_{j,c}$。每个成员包含编码消息、质量特征、来源类型、非负来源内先验及有效标记。

时间 Patch 证据。 候选来自当前窗口内同一变量的其他 Patch。目标两侧分别按距离分档，最近档优先邻近位置，较远档依据学习到的匹配选择。没有可见支撑的 Patch 不具备候选资格。每侧五档，最多十个候选。

跨变量 Patch 证据。 窗口相关的选择器将学习的变量关系与当前来源上下文结合，最多选择四个其他变量；每个来源提供时间偏移 $-1, 0, 1$ 的片段，最多十二个候选。可见性及共同可见位置的一致性参与质量计算。候选编码中保留目标潜表示和来源上下文。

历史 Patch 证据。 只由训练数据构建的记忆保存合法 Patch 成员及检索键。查询和检索辅助监督统一到训练集标准化坐标；局部归一化的查询在键编码前转换回该尺度。检索遵守来源变量与时间资格约束，从所选原型组返回最多四个成员，并将成员值转到目标工作尺度以构造消息。评价与精恢复训练时，发布的记忆快照和检索编码器保持固定。

统一证据库保留具体 Patch 成员、来源标记及支撑特征。质量特征与先验描述可观测支撑及兼容程度。当前结构在候选构建和逐点 Query 中均使用目标条件，其完整增量通过第5节的容量匹配上下文对照测量。

3.4 逐点证据引导重建（PEGR）

PEGR 将 Patch 证据转化为各目标点对上下文基础估计的残差修正。目标点利用点级上下文、Patch 潜表示 $z_{j,c}$、可见特征、片内位置、基础值及来源可用性构造 Query q_p。候选消息经归一化后，加入质量投影和来源类型嵌入，再生成 Key 和 Value。采用八个头，每头 $d_h = 8$ 维：

$$
\begin{aligned}
a_{p,k}^{(h)} &= \frac{\exp(\ell_{p,k}^{(h)})}{1 + \sum_{v \in \mathcal{C}_{j,c}} \exp(\ell_{p,v}^{(h)})}, \\
\ell_{p,k}^{(h)} &= \frac{\langle q_p^{(h)}, K_k^{(h)} \rangle}{\sqrt{d_h}} + \log \pi_k + \eta_k, \\
r_p &= \mathrm{Concat}_h \left(\sum_k a_{p,k}^{(h)} V_k^{(h)} \right), \\
\delta_p &= \mathbf{1}_{\exists k \in \mathcal{C}_{j,c}: \eta_k = 0}\, g_\theta([q_p; r_p]).
\end{aligned}
\tag{3}
$$

π_k 表示来源内先验；候选合法时 $\eta_k = 0$，否则为 $-\infty$。分母中的常数 1 对应零 logit、零 Value 的空候选，使证据不足时可以减弱读取量。残差头同时使用 Query 和拼接后的 readout；没有合法候选时，修正为零。

将 Patch 估计变换到训练集标准化尺度，再通过置信度加权重叠融合合并，学习正的重叠权重：

$$
\begin{aligned}
u_{j,p,c} &= \mu_c + \sigma_c b_{j,p,c} + s_c \delta_{j,p,c}, \\
s_c &= \sqrt{\sigma_c^2 + 0.1^2}, \\
w_{j,p,c} &= \exp\left(2 \tanh \frac{h_{j,p,c}}{2} \right), \\
X_{t,c}^{\mathrm{c}} &= \frac{\sum_{j: t \in \mathcal{P}_j} w_{j,t-jS,c} u_{j,t-jS,c}}{\sum_{j: t \in \mathcal{P}_j} w_{j,t-jS,c}}.
\end{aligned}
\tag{4}
$$

s_c 中的数值下限避免可见窗口几乎不变时，残差尺度随之坍缩。$h_{j,p,c}$ 由置信度网络生成，输入包括点级上下文、可见特征、位置、基础/候选数值及来源可用性。这些权重决定各重叠 Patch 估计对融合结果的贡献。融合时排除补齐位置，并恢复原可见值。

3.5 观测条件化残差精恢复（OCRR）

OCRR 将时间上下文与真实可见观测提供的数值锚点结合，修正初始恢复轨迹。第二阶段将固定粗估计与原可见观测结合。参考值 $R_{t,c}$ 由同变量最近的左右可见点线性插值；只有单侧可见点时使用该点。支撑特征 $U_{t,c}$ 随插值跨度或单侧距离衰减，不可用参考的支撑为零。

精恢复器将五类输入投影到 64 维，经过局部残差卷积及一层时间 Transformer [8]，产生两条修正：

$$\begin{aligned} D &= U \odot (\mathbf{R} - \mathrm{sg}(\mathbf{X}^{\mathrm{c}})), \\ Z &= \mathrm{TemporalEncoder}\big([\mathrm{sg}(\mathbf{X}^{\mathrm{c}}); \mathbf{X}_{\mathrm{obs}}; \mathbf{M}; D; U]\big), \\ \Delta_{\mathrm{net}} &= A_{\mathrm{win}} \odot 2\tanh(W_n Z/2), \\ G &= A_{\mathrm{var}} \odot \tanh(W_g Z), \\ \widetilde{\mathbf{X}} &= \mathbf{X}^{\mathrm{c}} + \Delta_{\mathrm{net}} + G \odot (\mathbf{R} - \mathrm{sg}(\mathbf{X}^{\mathrm{c}})), \\ \widehat{\mathbf{X}} &= \mathbf{M} \odot \mathbf{X}_{\mathrm{obs}} + (\mathbf{1} - \mathbf{M}) \odot \widetilde{\mathbf{X}}. \end{aligned} \tag{5}$$

该式的数值输入均位于训练集标准化坐标。sg 表示停止梯度，实际训练中整个粗模型冻结。激活标记为 $A_{\mathrm{win}} = \mathbf{1}[\sum_{t,c} M_{t,c} > 0]$ 和 $A_{\mathrm{var},c} = \mathbf{1}[\sum_t M_{t,c} > 0]$，按相应维度广播。第一条路径产生有界自由残差；第二条路径通过带符号门控 G 调节参考修正，只在该变量存在可见支撑时启用。整个窗口完全无观测时，网络修正关闭。最终掩码操作严格保留可见值。

3.6 训练与选模

先训练粗恢复，再固定其选定 checkpoint 训练精恢复器。在原本存在真值且被人工遮挡的位置，主要重建监督项为：

$$\begin{aligned} \mathcal{L}_{\mathrm{rec}}^{\mathrm{coarse}} &= \mathrm{MSE}_{\mathbf{E}}(\mathbf{X}^{\mathrm{c}}, \mathbf{X}), \\ \mathcal{L}_{\mathrm{rec}}^{\mathrm{refine}} &= \mathrm{MAE}_{\mathbf{E}}(\widehat{\mathbf{X}}, \mathbf{X}). \end{aligned} \tag{6}$$

训练结合上述重建项与辅助正则项；检索键监督将训练全局坐标中的掩码/完整键对齐与归一化对比监督结合。完整原生有效值只作为训练标签。两阶段均训练 100 轮，Adam 学习率 10^{-3}、权重衰减 0、FP32、batch128。粗模型按固定验证集全窗口 MSE 选模，精恢复按全窗口 MAE 选模。精恢复训练期间，粗网络、记忆成员和检索编码器全部冻结。

4 实验

4.1 数据集与评价协议

采用 ETTh1、Weather、Exchange-Rate、BeijingAirQuality、PhysioNet2012 和 PAMAP2，覆盖工业、气象、金融、环境、临床及可穿戴传感数据。处理后变量数分别为 7、21、8、12、35、40。BeijingAirQuality 将十二个站点视为相关通道。保留原生观测掩码，切窗时遵守患者、受试者及记录边界。尺度统计和历史库只使用训练数据。

四种固定缺失配置由块起点参数 p_s 和块长 b 组成：$(.10, 8)$、$(.15, 8)$、$(.20, 8)$ 及 $(.10, 16)$。实际遮挡覆盖由起点参数、块间重叠及边界处理共同决定。每组比较内部，各方法使用相同的测试遮挡，只在原本存在真值且被人工隐藏的位置评分。

采用 2023、2024、2025 三个训练种子，每个模型评价二十组固定测试遮挡。MSE 汇总为

$$
\begin{aligned}
m_{s,k}^{\mathrm{MSE}} &= \frac{\sum_{t,c} E_{t,c}^{(k)} (\widehat{X}_{t,c}^{(s,k)} - X_{t,c})^2}{\sum_{t,c} E_{t,c}^{(k)}}, \\
\overline{m}_s &= \frac{1}{20} \sum_{k=1}^{20} m_{s,k}, \\
\overline{m} &= \frac{1}{3} \sum_{s \in \{2023,2024,2025\}} \overline{m}_s.
\end{aligned}
\tag{7}
$$

MAE 使用对应绝对误差。报告三个训练种子对应 $\overline{m}_s$ 的均值与样本标准差。误差在训练集标准化尺度计算。主结果与专门的机制分析队列各自在比较内部使用固定共享遮挡。

4.2 六数据集正式结果

表1汇总 EviRefine 在六个数据集、四种缺失配置上的完整评价，同时报告 MSE 和 MAE，以观察平方误差与绝对误差。长块与较高起点率用于检验可见支撑减少时的恢复表现；后续配对实验进一步定位 Patch 证据与精恢复的作用。

4.3 受控对照

完整候选路径与容量匹配上下文模型比较。容量匹配上下文模型保留相同前端、基础预测、重叠融合及精恢复结构，以上下文恢复网络替代候选路径；通过解析确定隐藏宽度，将有效推理参数匹配在 1% 以内，新增参数实际参与预测。两者独立重训，数据、遮挡、优化预算及选模准则一致。

进一步分别移除时间、跨变量或历史证据；用来源内合法随机候选替代筛选；使用统一可见值相似度检索；或让目标 Patch 内部共享一次读取。随机与统一检索匹配参考有效候选预算，其余结构和精恢复训练不变。来源删除的差值表示该路径在完整系统中的条件收益。

在 BeijingAirQuality 上，额外将相同精恢复结构和预算应用于 T1、容量匹配上下文模型与 EviRefine，对照骨干原输出及接同一精恢复后的结果。训练精恢复时，各骨干权重冻结。

4.4 实现细节

主干宽度 64，逐点读取八头；精恢复采用一层宽 64、四头时间 Transformer。Patch 长度 16、步长 8。两阶段各 100 轮，EviRefine 比较中不提前停止；粗阶段按验证 MSE、精恢复按验证 MAE 选模，测试指标不参与权重选择。

效率使用同一独占 RTX5090、FP32 及固定 batch128 输入，先预热二十次，再同步计时一百次。报告推理中位延迟、有效参数及峰值 allocated 显存。训练循环时间包含验证和保存，与完整实验墙钟时间分开记录。

数据集	p_s	b	MSE ↓	MAE ↓
ETTh1	.10	8	0.116781 ± 0.001319	0.205465 ± 0.001606
ETTh1	.15	8	0.172229 ± 0.001825	0.256546 ± 0.001479
ETTh1	.20	8	0.261890 ± 0.001713	0.322662 ± 0.001965
ETTh1	.10	16	0.334986 ± 0.006672	0.372039 ± 0.004057
Weather	.10	8	0.042431 ± 0.000577	0.043479 ± 0.000306
Weather	.15	8	0.052501 ± 0.000742	0.053946 ± 0.000418
Weather	.20	8	0.064593 ± 0.001175	0.070304 ± 0.000500
Weather	.10	16	0.078572 ± 0.000796	0.092897 ± 0.000638
Exchange	.10	8	0.009212 ± 0.002400	0.057764 ± 0.012104
Exchange	.15	8	0.015368 ± 0.002077	0.073880 ± 0.007749
Exchange	.20	8	0.054194 ± 0.001231	0.098458 ± 0.001036
Exchange	.10	16	0.162275 ± 0.004526	0.172044 ± 0.001131
Beijing AQ	.10	8	0.077236 ± 0.000584	0.144566 ± 0.000524
Beijing AQ	.15	8	0.094839 ± 0.000677	0.163089 ± 0.000209
Beijing AQ	.20	8	0.122833 ± 0.001111	0.188204 ± 0.000303
Beijing AQ	.10	16	0.146832 ± 0.000833	0.206913 ± 0.000600
PhysioNet	.10	8	0.386760 ± 0.003590	0.343365 ± 0.001006
PhysioNet	.15	8	0.476532 ± 0.001034	0.403849 ± 0.000135
PhysioNet	.20	8	0.564794 ± 0.000846	0.455283 ± 0.000148
PhysioNet	.10	16	0.581826 ± 0.001249	0.469871 ± 0.000192
PAMAP2	.10	8	0.227562 ± 0.002636	0.181577 ± 0.001163
PAMAP2	.15	8	0.326661 ± 0.001309	0.230819 ± 0.000952
PAMAP2	.20	8	0.466878 ± 0.004067	0.292715 ± 0.000651
PAMAP2	.10	16	0.532003 ± 0.003002	0.334631 ± 0.001549

表 1: 六数据集正式 EviRefine 结果。每个模型先平均二十组共享测试遮挡，再汇总三个训练种子的均值 ± 样本标准差。p_s 为块起点参数，b 为块长；本表覆盖全部配置的 EviRefine 实测值。

5 模型分析

5.1 完整候选路径的价值

表2汇总 EviRefine 与容量匹配上下文模型的配对结果，覆盖 ETTh1 $(.10, 16)$ 和 PAMAP2 $(.15, 8)$。两数据集的三对训练种子均支持 EviRefine 具有更低的最终 MSE 和 MAE。最终 MSE 分别降低 5.19%、2.39%，MAE 分别降低 3.52%、1.66%。粗输出已经具有收益；对同一结构精恢复器独立训练后，差距仍然保留，说明显式 Patch 证据在容量匹配的上下文恢复之外提供了增量价值。

5.2 来源组织与逐点读取

表3中，在两个分析数据集上分别移除任一来源，都会增加最终平均 MSE。ETTh1 中跨变量证据的来源删除效应最大，PAMAP2 中时间证据最大，说明来源价值随信号特性而变化。

来源内随机选择与统一检索的平均 MSE 均高于完整结构，表明收益来自来源相关的组织，而不只是提供同等数量的合法片段。Patch 共享读取改变了精度取舍：其 ETTh1 MSE 更低，而逐

数据集	模型	粗 MSE	精 MSE	精 MAE
ETTh1	EviRefine	0.384873 ± 0.006236	0.334986 ± 0.006672	0.372039 ± 0.004057
ETTh1	上下文对照	0.408733 ± 0.001863	0.353320 ± 0.009562	0.385618 ± 0.010399
PAMAP2	EviRefine	0.336419 ± 0.000680	0.324572 ± 0.001591	0.230532 ± 0.000622
PAMAP2	上下文对照	0.351320 ± 0.002814	0.332533 ± 0.001960	0.234430 ± 0.001031

表 2: 候选路径配对分析。两个数据集均为三个训练种子，每模型平均二十组共享测试遮挡。PAMAP2 机制分析队列与表1的正式结果队列分开；粗精结果来自同一选定模型对。

变体	ETTh1 MSE	ETTh1 MAE	PAMAP2 MSE	PAMAP2 MAE
EviRefine	0.334986 ± 0.006672	0.372039 ± 0.004057	0.322915	0.230183
去时间证据	0.343612 ± 0.006384	0.381684 ± 0.004346	0.333096	0.235096
去跨变量证据	0.349493 ± 0.018407	0.381209 ± 0.010604	0.325663	0.231132
去历史证据	0.339364 ± 0.004246	0.376169 ± 0.002895	0.324277	0.231290
来源内随机	0.336177 ± 0.006092	0.377530 ± 0.004732	0.325863	0.231077
统一检索	0.339484 ± 0.005147	0.380305 ± 0.002030	0.331974	0.232928
无候选容量匹配	0.353320 ± 0.009562	0.385618 ± 0.010399	0.334383	0.235483
Patch 共享读取	0.333639 ± 0.004381	0.374103 ± 0.002174	0.323958	0.229965

表 3: 精恢复后的组件与检索对照。ETTh1 为三个训练种子均值 ± 样本标准差，PAMAP2 组件行统一使用 seed2023；每个模型均评价二十组共享遮挡。PAMAP2 的三种子 EviRefine 与容量匹配上下文模型对照单列于表2。

点读取具有更低的 ETTh1 MAE 与 PAMAP2 MSE。因此同时使用两种误差考察读取粒度。

5.3 观测条件化精恢复

在 EviRefine 配对队列中，精恢复将 ETTh1 MSE 从 0.384873 降至 0.334986，PAMAP2 从 0.336419 降至 0.324572，分别下降 12.96% 与 3.52%。该网络将时间修正与由可见观测锚定的参考信息结合。逐坐标诊断分别统计误差减少和增加的贡献，使总体修正能够追溯到具体位置。

表4进一步将同一精恢复应用于不同骨干。在 BeijingAirQuality$(.20, 8)$ 中，T1 的 MSE 从 0.225523 变为 0.129252，EviRefine 从 0.179570 变为 0.123941。公共精恢复解释了原输出差距中的较大部分，同时保留 EviRefine 粗估计的额外优势，从而区分骨干和精恢复的作用。

5.4 不同缺失条件下的诊断

按掩码定义的缺口长度、最近可见点距离、Patch 可见率和窗口边界分组，分组在读取预测前固定。ETTh1$(.10, 16)$ 中，到可见观测距离 17–32 及 33–95 的位置，在三个训练种子上均保持正向收益，支持 Patch 证据在局部观测稀少时发挥作用。对于所有覆盖 Patch 均无可见观测的坐标，模型仍可利用 Patch 外部上下文及其他证据来源恢复。完整分层数值与坐标支撑保存在数值证据表中。

骨干	粗 MSE	精 MSE	粗 MAE	精 MAE
T1	0.225523	0.129252	0.264340	0.193203
上下文对照	0.188083	0.124760	0.243393	0.189678
EviRefine	0.179570	0.123941	0.235067	0.188432

表 4: BeijingAirQuality$(.20, 8)$ 上三个冻结骨干接相同结构、相同预算精恢复的结果，seed2023，二十组测试遮挡。粗精误差在相同位置评价。

数据集	模型	参数	p50 (ms)	显存 (GiB)
PAMAP2	EviRefine	575,074	98.48	6.121
PAMAP2	上下文对照	574,794	55.53	4.122
ETTh1	EviRefine	353,248	17.63	1.067
ETTh1	上下文对照	352,968	11.51	0.709

表 5: 选定 seed2023 模型的推理成本；同一独占 RTX5090、FP32、batch128，二十次预热后进行一百次同步测量。显存为峰值 allocated。

5.5 精度与成本

表5量化候选路径的额外成本。EviRefine 与容量匹配上下文模型有效参数接近，候选构建与读取增加推理延迟和 allocated 显存。PAMAP2 中，两者参数分别为 575074 和 574794，完整流程每 batch 的 p50 延迟为 98.48 和 55.53ms，使精度收益能够与实际执行代价一起考察。

读取敏感性。 表6在总宽 64 不变时改变逐点读取头数。参数量不变，用于观察特征划分方式的影响。主模型保持预定八头配置，敏感性实验使用 seed2023 及验证选定权重。

头数	Val MSE	Val MAE	Test MSE	Test MAE
4	0.422429	0.427810	0.326837	0.370128
8	0.446899	0.436511	0.336727	0.373539
16	0.425259	0.428136	0.325889	0.369931

表 6: ETTh1(.10, 16) 上的逐点读取头数敏感性，总宽 64，seed2023，每模型二十组共享测试遮挡。

6 结论

本文提出粗到精多变量时间序列修复模型 EviRefine，将较强上下文估计、显式多来源 Patch 证据与观测条件化残差精恢复结合。容量匹配配对实验识别出完整证据路径的精度贡献，且收益在精恢复后保留。公共精恢复实验区分了骨干质量与第二阶段修正的作用。结合来源、读取粒度和成本分析，结果刻画了证据组织与数值精恢复如何共同改善缺失恢复。

LLM 使用说明

使用 OpenAI Codex 辅助实现、实验编排、数值表格整理、文献组织以及中英文写作和编辑。作者对方法、实验协议、数值来源、参考文献及最终科学结论负责。

参考文献

[1] Wei Cao, Dong Wang, Jian Li, Hao Zhou, Lei Li, and Yitan Li. Brits: Bidirectional recurrent imputation for time series, 2018.

[2] Wenjie Du, David Cote, and Yan Liu. Saits: Self-attention-based imputation for time series, 2023.

[3] Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. itransformer: Inverted transformers are effective for time series forecasting, 2024.

[4] Tong Nie, Guoyang Qin, Wei Ma, Yuewen Mei, and Jian Sun. Imputeformer: Low rankness-induced transformers for generalizable spatiotemporal imputation, 2024.

[5] Yuqi Nie, Nam H. Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. A time series is worth 64 words: Long-term forecasting with transformers, 2023.

[6] Dongik Park, Hyunwoo Ryu, Suahn Bae, Keondo Park, and Hyung-Sin Kim. T1: One-to-one channel-head binding for multivariate time-series imputation, 2026.

[7] Yusuke Tashiro, Jiaming Song, Yang Song, and Stefano Ermon. Csdi: Conditional score-based diffusion models for probabilistic time series imputation, 2021.

[8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017.

[9] Shiyu Wang, Jiawei Li, Xiaoming Shi, Zhou Ye, Baichuan Mo, Wenze Lin, Shengtong Ju, Zhixuan Chu, and Ming Jin. Timemixer++: A general time series pattern machine for universal predictive analysis, 2025.